



梯度下降



梯度下降算法-SGD

模型权值 w ，损失函数 $L(w)$

$$w_{t+1} = w_t - \alpha \frac{\partial L}{\partial w_t}$$

- 全样本学习
- 单样本Stochastic Gradient Descend (SGD)
- 小批量梯度下降Min-batch
 - 并不严格朝着最小方向
 - 摆动不能用大学习率

Momentum动量算法（梯度的指数滑动平均，Polyak, 1964）

使用带有动量的梯度（梯度的指数滑动平均，跟踪历史梯度之和）对 w 进行更新。 V 初始化为0， β 一般设置为0.9。

$$V_t = \beta V_{t-1} + (1 - \beta) \frac{\partial L}{\partial w_t}$$

$$w_{t+1} = w_t - \alpha V_t$$

- 有机会跳出局部最小值或鞍点(梯度为0时仍然可以下降)
- 在梯度方向改变时，降低参数更新速度，抑制震荡
- 在梯度方向相同时，加速参数更新，从而加速收敛

Nesterov momentum

动量项可视为对 SGD 算法下一步移动位置的粗略预测。Nesterov 加速动量不是在当前位置，而是在预测的位置计算梯度（预测下一个参数位置）。初值： $V_0 = 0, \beta = 0.9$ 。

$$w^* = w_t - \alpha V_{t-1}$$

$$V_t = \beta V_{t-1} + (1 - \beta) \frac{\partial L}{\partial w^*}$$

$$w_{t+1} = w_t - \alpha V_t$$

- 减少震荡，loss曲线更平滑
- 适应性更强(非平稳目标表现更好)

Adaptive Gradient (AdaGrad), (Duchi等, 2011)

SGD所有权值学习率相同，考虑不同权值自适应学习率。推荐初值 $\alpha = 0.01, \epsilon = 10^{-7}, S = 0$ 。

$$S_t = S_{t-1} + \left[\frac{\partial L}{\partial w_t} \right]^2$$

$$w_{t+1} = w_t - \frac{\alpha}{\sqrt{S_t} + \epsilon} \cdot \frac{\partial L}{\partial w_t}$$

- 自动为每个参数单独设置学习率
- Loss下降比较平稳（梯度大的参数学习率小，更新减慢；梯度小的参数学习率大，更新加速。）
- 分母会越来越大，学习率衰减快，甚至接近于0

Root Mean Square Propagation (RMSprop), (Hinton, 2012)

针对AdaGrad后期学习率小的问题，在学习率引入动量

$$S_t = \beta S_{t-1} + (1 - \beta) \left[\frac{\partial L}{\partial w_t} \right]^2$$

$$w_{t+1} = w_t - \frac{\alpha}{\sqrt{S_t + \epsilon}} \cdot \frac{\partial L}{\partial w_t}$$

- 克服了AdaGrad中，梯度消失的问题
- 学习率可能突然增大导致模型无法收敛

Adaptive Moment Estimation (Adam), (Kingma & Ba, 2014)

RMSprop加动量：学习率和梯度均使用动量。推荐初值 $\alpha = 0.001, \beta_1 = 0.9, \beta_2 = 0.999, \epsilon = 10^{-8}, V = G = 0$.

$$V_t = \beta_1 V_{t-1} + (1 - \beta_1) \frac{\partial L}{\partial w_t}$$

$$S_t = \beta_2 S_{t-1} + (1 - \beta_2) \left[\frac{\partial L}{\partial w_t} \right]^2$$

初始 V 和 S 为0，迭代缓慢，做偏差修正

$$\hat{V}_t = \frac{V_t}{1 - \beta_1^t}$$

$$\hat{S}_t = \frac{S_t}{1 - \beta_2^t}$$

$$w_{t+1} = w_t - \frac{\alpha}{\sqrt{\hat{S}_t + \epsilon}} \cdot \hat{V}_t$$

- 自适应学习率
- 快速收敛
- 适用于大规模数据
- 与RMSprop一样，学习率可能突然增大

AmsGrad (Reddi等, 2018)

RMSprop系列(包括Adam)学习率可能上升，导致无法收敛。推荐初值 $\alpha = 0.001, \beta_1 = 0.9, \beta_2 = 0.999, \epsilon = 10^{-7}$.

$$V_t = \beta_1 V_{t-1} + (1 - \beta_1) \frac{\partial L}{\partial w_t}$$

$$S_t = \beta_2 S_{t-1} + (1 - \beta_2) \left[\frac{\partial L}{\partial w_t} \right]^2$$

$$\hat{S}_t = \max(\hat{S}_{t-1}, S_t)$$

$$w_{t+1} = w_t - \frac{\alpha}{\sqrt{\hat{S}_t} + \epsilon} \cdot V_t$$

- 确保 S_t 一直变大，学习率一定衰减。